1. Model description (2%)：

Generator:

主結構：(all kernel_initializer='lecun_normal')

Concatenate(noise_input, text_input)
Dense(65536)
Activation(ReLu)
Reshape(16 * 16 * 256)
Conv2DTranspose(filter=64, [3, 3], stride=[2, 2], padding='same')
Activation(ReLu)
Conv2DTranspose(filter=32, [5, 5], stride=[2, 2], padding='same')
Activation(ReLu)
Conv2DTranspose(filter=16, [5, 5], stride=[1, 1], padding='same')
Activation(ReLu)
Conv2DTranspose(filter= 3, [1, 1], stride=[1, 1], padding='same')
Activation(Sigmoid)

輸入：

noise_input: dim = 40
text_input: dim = 24

輸出：

dim = 64 * 64 * 3

Discriminator:

主結構：(all kernel_initializer='lecun_normal')

Conv2D(filter=64, [5, 5], stride=[2, 2], padding='same')
Activation(ReLu) + AlphaDropout(0.2)
Conv2D(filter=128, [5, 5], stride=[2, 2], padding='same')
Activation(ReLu) + AlphaDropout(0.2)
Conv2D(filter=256, [3, 3], stride=[2, 2], padding='same')
Activation(ReLu) + AlphaDropout(0.2)
Conv2D(filter=256, [3, 3], stride=[2, 2], padding='same')
Activation(ReLu) + AlphaDropout(0.2)
Concatenate repeated text_input at the last dimenion of the 4*4*256 net.
Conv2D(filter=512, [4, 4], stride=[1, 1], padding='valid')
Activation(ReLu) + AlphaDropout(0.2) + Flatten
Dense(1, activation='linear')

輸入：

img_input: dim = 64 * 64 * 3
text_input: dim = 24

輸出：

dim = 1

Objective function:

$$L_D^{WGAN\_GP} = L_D^{WGAN} - \lambda E[(\|\nabla D(\alpha x + (1-\alpha)G(z))\|_2 - 1)^2]$$
$$L_G^{WGAN\_GP} = L_G^{WGAN}$$

loss_true_case = mean(D([true_img, true_txt]))
loss_fake_case = mean(D([fake_img, true_txt]))
loss_wrong_txt =mean(D([true_img, wrong_txt]))
mixed_img = mix_factor * true_img + (1. - mix_factor) * fake_img
mixed_grad = gradients(D([mixed_img, true_txt]), w.r.t: [mixed_img, true_txt])
norm_mixed_grad = sqrt(sum(square(mixed_grad[0]), axis=[1, 2, 3]) +
sum(square(mixed_grad[1]), axis=[1]))
grad_penalty = mean(square(norm_mixed_grad - 1.))
**obj_d = loss_true_case - 0.5 * loss_fake_case - 0.5 * loss_wrong_txt -
penalty_factor * grad_penalty**
optimizers_d: Adam(lr=2e-4, beta_1=0., beta_2=0.9, loss= - obj_d)

obj_g = loss_fake_case
optimizers_d: Adam(lr=2e-4, beta_1=0., beta_2=0.9, loss= - obj_g)

2. How do you improve your performance (2%)
   a. wgan_GP: 相較於basic gan更快學習到臉型特徵與髮色、眼睛色等特徵，且較少輸出壞掉的機率。對於模型結構容忍度高，不容易trian不起來。
   b. kernel_initializer='lecun_normal：使用正確分佈的初始化值可以加速模型進入狀況、減少發散的機會。
   c. 使用Dense layer作為generator的初始結構，可以減少輸出圖片有方塊狀的格紋，讓整個構圖較連續自然。
   d. 圖片預處理：將color channel除以255以將數據分佈縮至[0, 1]。
   e. text預處理：將12種髮色與11種眼睛色分別以onehot encode至24維vector，再將同時符合的vector “OR” 在一起。

3. Experiment settings and observation (2%)

使用Dense layer作為generator的初始結構，可以減少輸出圖片有方塊狀的格紋，讓整個構圖較平順自然。

a. 使用Conv2D(padding='valid')作為初始結構：

Epoch 30

可見許多格狀干擾紋，較不自然，但較早學習到部份顏色分類。另外，在後期（500 epoch up)的結果中細節較少、模糊而粗糙。

b. 使Dense作為初始結構：

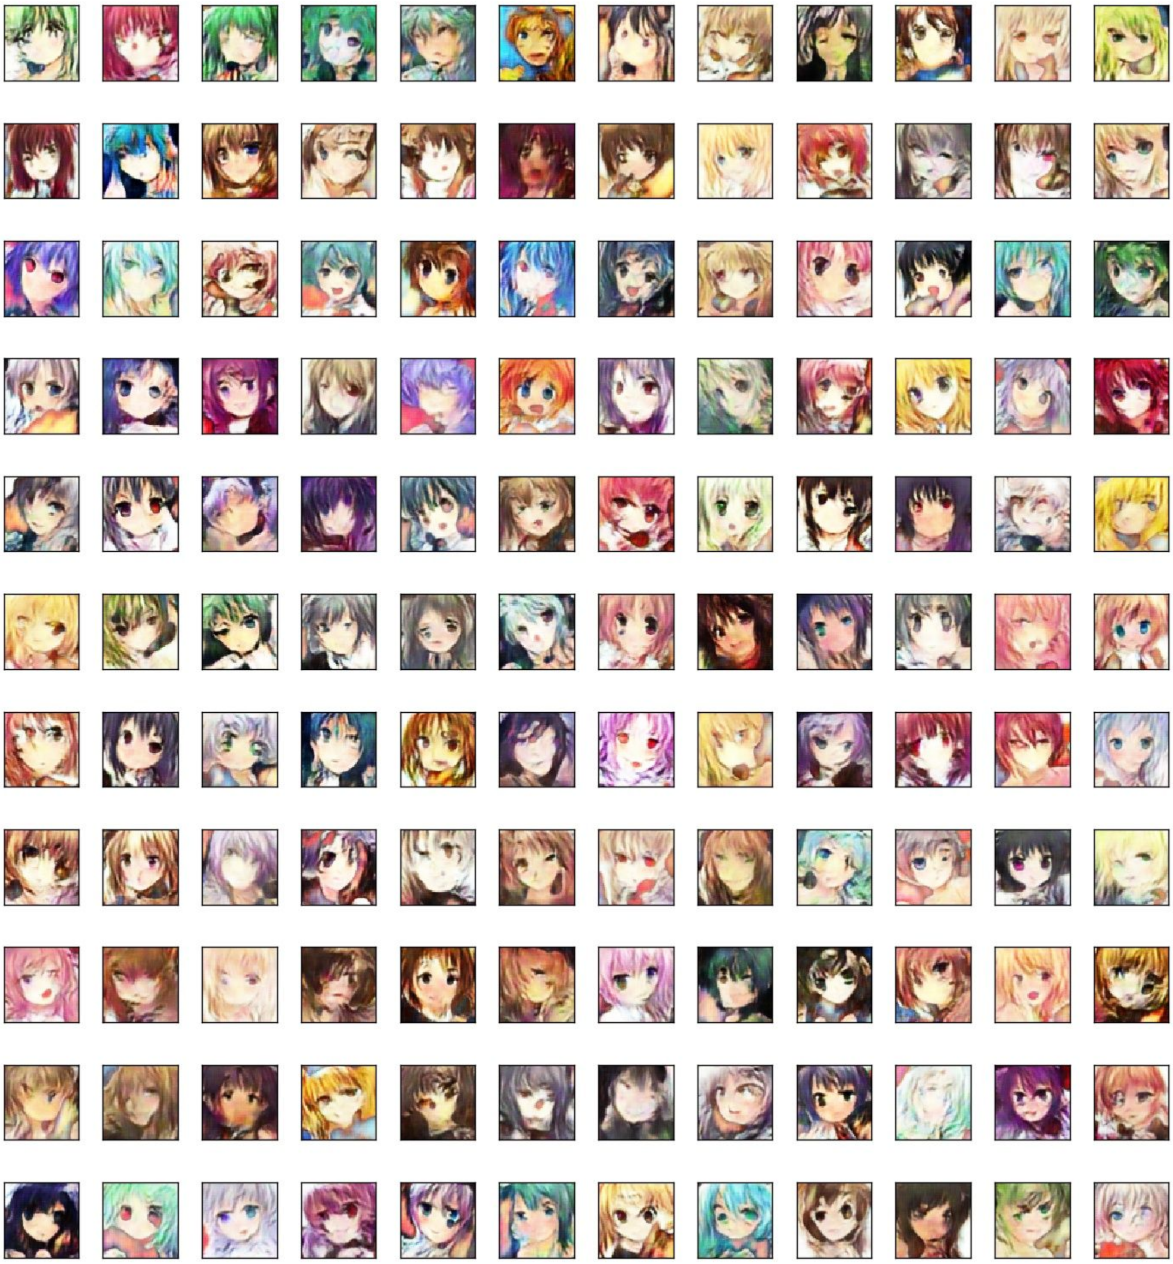

Epoch 30

可見一開始圖形就相當完整連續且多樣化，但晚一些學到顏色類。後期結果保有較多細節。

4. style-transfer (2%)
   實作Cycle GAN
   (Result @ 47 epoch)

dataset_A = Anime Dataset

dataset_B = celebA Dataset

A->B

B->A

A->B->A

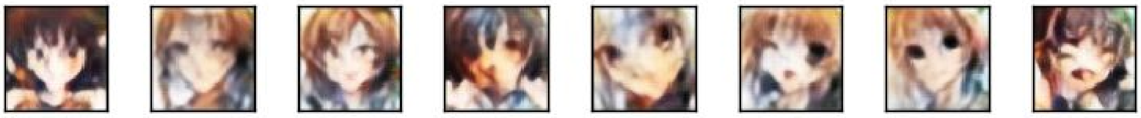

B->A->B

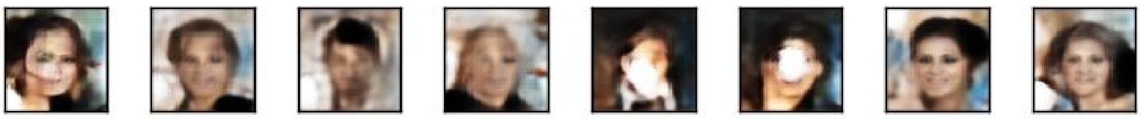

Loss plot、架構：礙於篇幅，請參閱cycle_gan_2_celebA資料夾。